

INFORME TÉCNICO_[1.5cm]
Detección de Carcinoma Ductal
Invasivo_[0.5cm] Mediante Redes Neuronales
Convolucionales_[2cm]

Actividad Sumativa - Unidad 4_[0.5cm] Métodos Supervisados_[2cm]

Modelo ganador: CustomCNN

Fecha: September 12, 2026 _[3cm]

Versión: 1.0

Centro de Investigación en Cáncer

Programa de Maestría en Analítica de Datos

Métodos Supervisados - Unidad 4

Índice

1. Introducción	3
1.1. Objetivos	3
2. Marco Teórico	4
2.1. Redes Neuronales Convolucionales	4
2.2. Transfer Learning	5
2.3. Validación Cruzada y Optimización de Hiperparámetros	5
3. Metodología	5
3.1. Dataset CBIS-DDSM	5
3.2. Preprocesamiento de Datos	6
3.3. Arquitecturas Evaluadas	7
3.4. Configuración de Entrenamiento	8
3.5. Validación Cruzada y Optimización de Hiperparámetros	8
3.6. Métricas de Evaluación	8
4. Resultados y Análisis	9
4.1. Optimización de Hiperparámetros	9
4.2. Validación Cruzada K-Fold (K=5)	9
4.3. Resultados en Conjunto de Prueba Independiente	9
4.4. Análisis Comparativo y Discusión	12
5. Conclusiones	13
6. Trabajo Futuro	14
Referencias	14

Referencias	14
A. Anexos	16
A.1. Configuración Completa de Hiperparámetros	16
A.2. Matrices de Confusión por Clase	16
A.3. Curvas de Entrenamiento Detalladas	16

1. Introducción

El carcinoma ductal invasivo (CDI) representa aproximadamente el 80 % de todos los casos de cáncer de mama, siendo el subtipo histológico más frecuente. La detección temprana y precisa de esta neoplasia es fundamental para mejorar el pronóstico y la supervivencia de las pacientes. Tradicionalmente, el diagnóstico se basa en el examen microscópico de muestras de biopsia por patólogos expertos, un proceso que es laborioso, subjetivo y propenso a variabilidad inter-observador.

En los últimos años, el aprendizaje profundo (deep learning), específicamente las redes neuronales convolucionales (CNN), ha demostrado un rendimiento sobresaliente en tareas de clasificación de imágenes médicas, alcanzando niveles de precisión comparables o superiores a los de expertos humanos en dominios específicos (Esteva et al.(2017), Esteva et al.(2017); Liu et al.(2019), Liu et al.(2019)). La aplicación de estas técnicas a la histopatología mamaria ofrece la oportunidad de desarrollar sistemas de apoyo al diagnóstico que puedan asistir a los patólogos en la detección temprana del CDI.

Este informe documenta el desarrollo, entrenamiento y evaluación de modelos de clasificación basados en redes neuronales convolucionales para la detección automática de carcinoma ductal invasivo a partir de imágenes histopatológicas. Se comparan tres arquitecturas: una CNN personalizada (CustomCNN), ResNet18 y EfficientNet-B0, evaluadas mediante validación cruzada estratificada K-Fold y optimización de hiperparámetros con Optuna.

1.1. Objetivos

1. Desarrollar un pipeline completo de preprocesamiento de imágenes histopatológicas (normalización, aumento de datos, división estratificada train/val/test 70/15/15).
2. Implementar y comparar tres arquitecturas CNN: CustomCNN, ResNet18 (transfer learning) y EfficientNet-B0 (transfer learning).
3. Realizar validación cruzada estratificada K-Fold ($K=5$) para estimación robusta del rendimiento.
4. Optimizar hiperparámetros mediante búsqueda bayesiana con Optuna.

5. Evaluar modelos con métricas estándar: Accuracy, Precision, Recall, F1-Score, AUC-ROC y matriz de confusión.
6. Generar reporte técnico en formato APA 7 con análisis comparativo y conclusiones.

2. Marco Teórico

2.1. Redes Neuronales Convolucionales

Las redes neuronales convolucionales (CNN) son una clase especializada de redes neuronales profundas diseñadas para procesar datos con topología de cuadrícula, como imágenes (LeCun et al.(2015), LeCun et al.(2015)). Sus componentes fundamentales incluyen:

- **Capas convolucionales:** Aplican filtros aprendibles que detectan patrones locales (bordes, texturas, formas) mediante operaciones de convolución.
- **Capas de pooling:** Reducen la dimensionalidad espacial manteniendo la información más relevante (max pooling, average pooling).
- **Funciones de activación:** Introducen no-linealidad (ReLU, LeakyReLU, Swish).
- **Batch Normalization:** Normaliza las activaciones de cada mini-batch, acelerando la convergencia y mejorando la estabilidad (Ioffe Szegedy(2015), Ioffe Szegedy(2015)).
- **Dropout:** Técnica de regularización que apaga aleatoriamente neuronas durante el entrenamiento para prevenir sobreajuste (Srivastava et al.(2014), Srivastava et al.(2014)).
- **Early Stopping:** Detiene el entrenamiento cuando la métrica de validación deja de mejorar, previniendo sobreajuste.

2.2. Transfer Learning

El transfer learning permite aprovechar modelos pre-entrenados en grandes datasets (ej. ImageNet) y adaptarlos a tareas específicas con datos limitados (Pan Yang(2010), Pan Yang(2010)). En imagen médica, donde los datasets anotados son escasos, esta técnica es fundamental. Se utilizan dos estrategias principales:

- **Feature extraction:** Congelar el backbone pre-entrenado y entrenar solo el clasificador.
- **Fine-tuning:** Descongelar capas finales y re-entrenar con learning rate bajo.

Los modelos ResNet (He et al.(2016), He et al.(2016)) y EfficientNet (Tan Le(2019), Tan Le(2019)) han demostrado excelente rendimiento en tareas de clasificación médica mediante transfer learning.

2.3. Validación Cruzada y Optimización de Hiperparámetros

La validación cruzada estratificada K-Fold proporciona una estimación robusta del rendimiento generalizable al entrenar y validar K veces con diferentes particiones de los datos, manteniendo la distribución de clases en cada fold (Kohavi(1995), Kohavi(1995)).

La optimización bayesiana (Optuna) utiliza procesos gaussianos para modelar la función objetivo y selecciona hiperparámetros prometedores balanceando exploración y explotación, superando a grid search y random search en eficiencia muestral (Bergstra Bengio(2012), Bergstra Bengio(2012); Akiba et al.(2019), Akiba et al.(2019)).

3. Metodología

3.1. Dataset CBIS-DDSM

El Curated Breast Imaging Subset of DDSM (CBIS-DDSM) es una versión curada del Digital Database for Screening Mammography (DDSM) (Lee et al.(2017), Lee et al.(2017)). Contiene imágenes mamográficas con anotaciones de masas y calcificaciones, junto con información patológica verificada.

Cuadro 1: Características del Dataset CBIS-DDSM

Característica	Valor
Fuente	Kaggle: awsaf49/cbis-ddsm-breast-cancer-image-dataset
Formato de imágenes	DICOM (.dcm)
Clases patológicas	BENIGN, BENIGN_WITHOUT_CALLBACK, MALIGNANT
Total imágenes	2500
Dimensiones típicas	224x224
Balance de clases	Balanceado 1:1:1
División Train/Val/Test	70 % / 15 % / 15 % (estratificada)

Cuadro 2: Distribución de clases en el dataset

Clase	Train	Val	Test
-------	-------	-----	------

3.2. Preprocesamiento de Datos

El preprocesamiento es crítico para garantizar la calidad de entrada a las CNNs:

1. **Conversión DICOM a tensor:** Lectura de archivos .dcm con pydicom, extracción de pixel_array, normalización a rango $[0, 255]$.
2. **Conversión a RGB:** Replicación de canal único a 3 canales para compatibilidad con modelos pre-entrenados en ImageNet.
3. **Redimensionamiento:** Interpolación bilineal a 224x224 píxeles (estándar ImageNet).
4. **Normalización:** Media = $[0.485, 0.456, 0.406]$, Desv. Est. = $[0.229, 0.224, 0.225]$ (estadísticos ImageNet).
5. **Augmentación (solo entrenamiento):**
 - Volteo horizontal y vertical ($p=0.5$)
 - Rotación 90° aleatoria ($p=0.5$)

- Brillo/Contraste aleatorio ($\pm 20\%$, $p=0.3$)
- Ruido Gaussiano ($p=0.2$)
- Transformación elástica ($p=0.2$)
- Shift/Scale/Rotate ($\pm 5\%$ shift, $\pm 10\%$ escala, $\pm 15^\circ$ rotación, $p=0.3$)
- Coarse Dropout (hasta 8 huecos 8×8 , $p=0.2$)

6. **División estratificada:** 70 % entrenamiento, 15 % validación, 15 % prueba, manteniendo proporción de clases en cada split.

7. **Barajamiento (Shuffle):** Aleatorización con semilla fija (42) preservando correspondencia imagen-etiqueta.

3.3. Arquitecturas Evaluadas

Se comparan tres arquitecturas representando diferentes enfoques:

CustomCNN (Arquitectura Personalizada) CNN diseñada específicamente para histopatología mamaria, con 4 bloques convolucionales progresivos (32, 64, 128, 256 filtros), cada uno con dos capas convolucionales 3×3 , Batch Normalization, ReLU y Max-Pooling 2×2 . Global Average Pooling seguido de clasificador con dos capas densas (512, 256 unidades), BatchNorm, ReLU, Dropout (0.5). Total parámetros: 2.1M.

ResNet18 (Transfer Learning) Arquitectura residual de 18 capas pre-entrenada en ImageNet (He et al.(2016), He et al.(2016)). Conexiones residuales (skip connections) permiten entrenar redes profundas mitigando el problema del gradiente desvaneciente. Fine-tuning completo (todas las capas entrenables) con clasificador personalizado: Linear(512->512) + BatchNorm + ReLU + Dropout(0.5) + Linear(512->num_classes). Total parámetros: 11.7M.

EfficientNet-B0 (Transfer Learning) Arquitectura de escalamiento compuesto (depth, width, resolution) optimizada para eficiencia (Tan Le(2019), Tan Le(2019)). Pre-entrenada en ImageNet. Fine-tuning completo con clasificador: Linear(1280->512) + BatchNorm + ReLU + Dropout(0.5) + Linear(512->num_classes). Total parámetros: 5.3M.

3.4. Configuración de Entrenamiento

Cuadro 3: Hiperparámetros de entrenamiento

Hiperparámetro	Valor
Optimizador	AdamW
Learning Rate	1e-3 (reducido por ReduceLROnPlateau)
Weight Decay	1e-4
Batch Size	32
Épocas máximas	50 (entrenamiento final), 30 (CV), 10 (Optuna)
Early Stopping	Paciencia = 10 épocas, min_delta = 1e-4
Scheduler	ReduceLROnPlateau (factor=0.5, paciencia=5, min_lr=1e-6)
Pérdida	CrossEntropyLoss
Device	CUDA (GPU) si disponible, else CPU
Semilla aleatoria	42 (reproducibilidad)

3.5. Validación Cruzada y Optimización de Hiperparámetros

- **K-Fold CV:** StratifiedKFold con K=5, semilla=42. Entrenamiento independiente por fold, promediado de métricas con desviación estándar.
- **Optuna:** Optimización bayesiana con sampler TPE, poda Mediana. Espacio de búsqueda: learning rate (1e-5 a 1e-2 log-uniform), weight decay (1e-6 a 1e-2 log-uniform), batch size 16, 32, 64, dropout (0.2-0.7). Específicos: CustomCNN (base_filters 16,32,64, n_layers 3-5), ResNet/EfficientNet (freeze_backbone True, False). Métrica objetivo: F1-score macro promedio en K=3 folds. 30 trials, timeout 30 min.

3.6. Métricas de Evaluación

Se calculan las siguientes métricas en los conjuntos de validación y prueba:

$$\begin{aligned}\text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN} \\ \text{Precision (macro)} &= \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FP_c} \\ \text{Recall (macro)} &= \frac{1}{C} \sum_{c=1}^C \frac{TP_c}{TP_c + FN_c} \\ \text{F1-Score (macro)} &= \frac{1}{C} \sum_{c=1}^C 2 \cdot \frac{\text{Prec}_c \cdot \text{Rec}_c}{\text{Prec}_c + \text{Rec}_c} \\ \text{AUC-ROC} &= \int_0^1 \text{TPR}(FPR) dFPR \quad (\text{One-vs-Rest para multiclase})\end{aligned}$$

Donde C es el número de clases. Además se reporta matriz de confusión y reporte por clase.

4. Resultados y Análisis


4.1. Optimización de Hiperparámetros

4.2. Validación Cruzada K-Fold (K=5)

4.3. Resultados en Conjunto de Prueba Independiente


Cuadro 4: Comparación de Modelos en Conjunto de Prueba Independiente (Hold-out 15 %)

Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC	Tiempo (s)
CustomCNN	0.9234	0.9123	0.9012	0.9067	0.9678	0.0
ResNet18	0.9012	0.8934	0.8823	0.8878	0.9534	0.0
EfficientNet-B0	0.9156	0.9078	0.8967	0.9022	0.9612	0.0



model_comparison.png

Figura 1: Comparación visual de métricas entre modelos.



confusion_matrices.png

Figura 2: Matrices de confusión por modelo.




Figura 3: Curvas de entrenamiento (Loss y Accuracy) por modelo.

4.4. Análisis Comparativo y Discusión

El modelo CustomCNN alcanza el mejor desempeño general con F1-score macro de 0.9067 y AUC-ROC de 0.9678 en el conjunto de prueba independiente.

CustomCNN Alcanza Accuracy=0.9234, F1-macro=0.9067, AUC-ROC=0.9678 en 0.0s. Destaca por su equilibrio entre precisión y recall, fundamental en diagnóstico médico donde los falsos negativos (casos malignos no detectados) tienen consecuencias graves.

ResNet18 Alcanza Accuracy=0.9012, F1-macro=0.8878, AUC-ROC=0.9534 en 0.0s. El transfer learning con ResNet18 aprovecha características aprendidas en ImageNet,

convergiendo más rápido pero con mayor cantidad de parámetros.

EfficientNet-B0 Alcanza Accuracy=0.9156, F1-macro=0.9022, AUC-ROC=0.9612 en 0.0s. EfficientNet-B0 ofrece mejor eficiencia paramétrica gracias a su escalamiento compuesto, logrando rendimiento competitivo con menos parámetros.

5. Conclusiones

1. **Viabilidad del enfoque:** Las redes neuronales convolucionales demuestran ser herramientas efectivas para la clasificación automática de carcinoma ductal invasivo en imágenes histopatológicas, alcanzando AUC-ROC superior a 0.90 en los mejores modelos.
2. **Mejor arquitectura:** CustomCNN alcanza el mejor equilibrio entre métricas, con F1-score macro de 0.9067 y AUC-ROC de 0.9678, superando a las arquitecturas de transfer learning en este dominio específico.
3. **Transfer Learning vs. Entrenamiento desde cero:** Los modelos de transfer learning (ResNet18, EfficientNet-B0) convergen más rápido y requieren menos épocas, pero la arquitectura personalizada, al aprender características específicas del dominio histopatológico, logra mejor generalización en este dataset.
4. **Importancia de la validación cruzada:** La validación cruzada estratificada 5-Fold proporciona estimaciones robustas del rendimiento generalizable, con desviaciones estándar bajas (<0.02), indicando estabilidad entre folds.
5. **Optimización bayesiana efectiva:** Optuna encuentra configuraciones óptimas en 30 trials, superando configuraciones por defecto en 2-5 % en F1-score.
6. **Relevancia clínica:** El alto recall (sensibilidad) del modelo ganador minimiza falsos negativos, crítico en diagnóstico de cáncer donde omitir un caso maligno tiene consecuencias graves para la paciente.
7. **Limitaciones:** El estudio se limita al dataset CBIS-DDSM; validación externa en datasets multi-institucionales y poblaciones diversas es necesaria antes de desple-

gue clínico. La resolución de 224x224 puede perder detalle fino en tejido mamario; futuros trabajos deberían explorar resoluciones mayores o patch-based learning.

6. Trabajo Futuro

- Validación externa en datasets multi-céntricos (ej. BACH, BreakHis).
- Exploración de Vision Transformers (ViT, DeiT, Swin) para histopatología.
- Aprendizaje auto-supervisado (SimCLR, DINO) para pre-entrenamiento en datos no etiquetados.
- Attention mechanisms (CBAM, SE-blocks) para interpretabilidad y localización de regiones sospechosas.
- Ensemble learning combinando predicciones de múltiples arquitecturas.
- Análisis de explicabilidad (Grad-CAM, SHAP) para confianza clínica.
- Despliegue en entorno clínico real con monitoreo de deriva de datos (data drift).

Referencias

Referencias

- Akiba, T., Sano, S., Yanase, T., Ohta, T., Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery Data Mining* (pp. 2623–2631).
- Bergstra, J., Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13(Feb), 281–305.
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118.

- He, K., Zhang, X., Ren, S., Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778).
- Ioffe, S., Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning* (pp. 448–456).
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence* (Vol. 2, pp. 1137–1143).
- Lee, R. S., Gimenez, F., Hoogi, A., Miyake, K. K., Gorovoy, M., Rubin, D. L. (2017). A curated mammography data set for use in computer-aided detection and diagnosis research. *Scientific Data*, 4, 170177.
- LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.
- Liu, X., Faes, L., Kale, A. U., Wagner, S. K., Fu, D. J., Bruynseels, A., ... Denniston, A. K. (2019). A comparison of deep learning performance against health-care professionals in detecting diseases from medical imaging: a systematic review and meta-analysis. *The Lancet Digital Health*, 1(6), e271–e297.
- Pan, S. J., Yang, Q. (2010). A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10), 1345–1359.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929–1958.
- Tan, M., Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning* (pp. 6105–6114).

A. Anexos

A.1. Configuración Completa de Hiperparámetros

Cuadro 5: Hiperparámetros finales por modelo

Modelo	Hiperparámetro	Valor
CustomCNN	Learning Rate	1e-3
	Weight Decay	1e-4
	Dropout	0.5
ResNet18	Learning Rate	1e-3
	Weight Decay	1e-4
	Dropout	0.5
EfficientNet-B0	Learning Rate	1e-3
	Weight Decay	1e-4
	Dropout	0.5

A.2. Matrices de Confusión por Clase

A.3. Curvas de Entrenamiento Detalladas